



Curso Métodos y Modelos

Profesora:
Karen Ballesteros-González PhD.

Modelos Basados en Datos

Modelos Estadísticos

- i. Regresión lineal y no lineal (Ej. predicción de tendencias)
- ii. Análisis de series temporales (Ej. modelos para pronóstico de demanda)

Objetivo:

Introducir y aplicar modelos estadísticos y de aprendizaje automático para análisis y predicción de datos, incluyendo regression y series temporales.

Modelos Estocásticos – Método de Monte Carlo

Ejercicio: Modelo Estocástico de Reforestación y Captura de Carbono

Este ejercicio simula el crecimiento del área de un bosque reforestado durante 20 años, considerando la posibilidad de eventos aleatorios que afectan dicho crecimiento.

Descripción del modelo

Cada año, el área del bosque puede crecer o reducirse dependiendo de un evento aleatorio:

- **Incendio** (probabilidad = 0.2): reduce el área en un 30%.
- **Plaga** (probabilidad = 0.1): reduce el área en un 15%.
- **Protección** (probabilidad = 0.3): aumenta la tasa de crecimiento a 8%.
- **Sin evento** (probabilidad = 0.4): el crecimiento se mantiene en 5%.

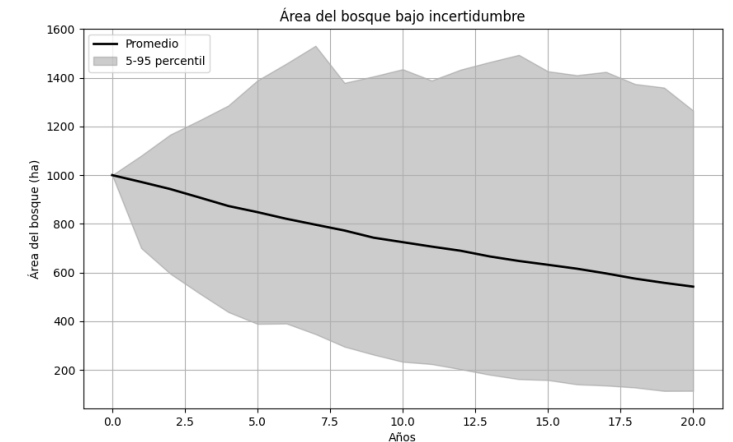
La ecuación básica de crecimiento de bosque es:

$$A_t = A_{t-1} \times (1 + r_t)$$

Donde:

A_t : área del bosque en el año (t)

r_t : tasa de crecimiento o decrecimiento, según el evento ocurrido en el año (t)



Ejercicio: Cadenas de Markov y Probabilidad de Sismos

AutoSave

Home

Insert

Draw

Page Layout

Formulas

Data

Review

View

Acrobat

Paste

Arial

10

A⁻

A⁺

B

I

U

General

\$

%

Conditional Formatting

Format as Table

Cell Styles

Insert

Delete

Format

Sort & Filter

Find & Select

Add-ins

Analyze Data

Copilot

Create PDF and share link

Comments

Share

T14

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S
	No.	Fecha	Hora local	centro Lat	centro Long	Epice	Magnitud	agntud	Tipor	Magnit	Profundidad	Profundimero	puntnsidad	max	Escala	Autor	Intensidad	Area epicentral	
1	1	1644/01/16	05:00	7.37	72.64	Sarabia G8	5.5	MW	Sarabia G8	15	Sarabia G8	5	9	EMS-98	Cifuentes, H., Sarabiz Pamplona, Norte de Santander				
2	2	1644/03/16	12:00	4.46	74.04	Dimat	5.5	MW	Sarabia G8	15	Sarabia G8	2	7	EMS-98	Sarabia, A., Cifuentes Chipaque, Cundinamarca				
3	3	1646/04/03	02:00	5.52	74.13	Sarabia G8	5	MW	Sarabia G8	15	Sarabia G8	2	6	EMS-98	Sarabia, A., Cifuentes Muzo, Boyacá				
4	4	1736/02/02	09:00	2.5	76.5	Sarabia G8	5	MW	Sarabia G8	15	Sarabia G8	1	6	EMS-98	Sarabia, A., Cifuentes Popayán, Cauca				
5	5	1743/10/18	10:45	4.44	73.83	Sarabia G8	5.2	MW	Sarabia G8	15	Sarabia G8	13	6	EMS-98	Sarabia, A., Cifuentes Fómeque, Cundinamarca				
6	6	1766/07/09	16:00	3.82	76.52	Sarabia G8	5.5	MW	Sarabia G8	15	Sarabia G8	5	6	EMS-98	Cifuentes, H., Sarabiz Buga, Valle del Cauca				
7	7	1785/07/12	07:45	3.42	74.23	Sarabia, A.	7.1	MW	G´acute;acute;ute,	10	G´acute;acute;ute,	17	7	EMS-98	Sarabia, A., Cifuentes Piedemonte Ilanero, Colombia				
8	8	1796/02/15	12:00	7.37	72.64	Sarabia G8	5.5	MW	Sarabia G8	15	Sarabia G8	1	7	EMS-98	Cifuentes, H., Sarabiz Pamplona, Norte de Santander				
9	9	1805/06/16	03:15	5.37	74.87	Sarabia G8	5.1	MW	Sarabia G8	15	Sarabia G8	7	9	EMS-98	Cifuentes, H., Sarabiz Honda, Tolima				
10	10	1807/02/17	12:02	6.5	71.7	Sarabia G8	5.5	MW	Sarabia G8	15	Sarabia G8	1	7	EMS-98	Barbosa Castro, D. Tame, Arauca				
11	11	1826/06/17	22:30	5.01	73.59	Sarabia G8	5.5	MW	Sarabia G8	15	Sarabia G8	11	8	EMS-98	Sarabia, A., Cifuentes Umbita, Boyacá				
12	12	1827/11/16	18:00	1.8	75.52	G´acute;acute;ute,	7.1	MW	G´acute;acute;ute,	10	G´acute;acute;ute,	19	10	EMS-98	Sarabia, A., Cifuentes Altamira, Huila				
13	13	1834/01/20	07:00	1.1	76.93	Sarabia G8	5.7	MW	Sarabia G8	15	Sarabia G8	29	9	EMS-98	Sarabia, A., Cifuentes Santiago, Putumayo				
14	14	1834/05/22	03:00	1.149	74.07	G´acute;acute;ute,	6.4	MW	G´acute;acute;ute,	10	G´acute;acute;ute,	19	8	EMS-98	Cifuentes, H., Sarabiz Santa Marta, Magdalena				
15	15	1869/03/06	06:30	9	74	Sarabia G8	5.1	MW	Sarabia G8	50	Sarabia G8	75	7	EMS-98	Sarabia G´acute;ute,	mi El Banco, Magdalena			
16	16	1875/05/18	11:15	7.86	72.42	Sarabia G8	5.8	MW	Sarabia G8	15	Sarabia G8	54	10	EMS-98	Cifuentes, H., Sarabiz Cúcuta, Norte de Santander				
17	17	1882/09/07	03:20	10	79	Camacho,	6.5	MW	Sarabia G8	15	Sarabia G8	17	9	EMS-98	Sarabia, A., Cifuentes Colón, Colón-Panamá				
18	18	1884/11/05	23:45	5.1	75.5	Espinosa B	6.3	MS	Ceresis (15	60	Servicio Ge	14	8	EMS-98	Cifuentes, H., Sarabiz Hervey, Tolima				
19	19	1885/05/25	15:05	2.88	76.54	Sarabia G8	5.4	MW	Sarabia G8	15	Sarabia G8	8	6	EMS-98	Cifuentes, H., Sarabiz El Tambo, Cauca				
20	20	1903/12/01	08:00	6.78	76.14	Sarabia G8	5.5	MW	Sarabia G8	15	Sarabia G8	2	7	EMS-98	Cifuentes, H., Sarabiz Frontino, Antioquia				
21	21	1906/01/31	10:36	0.988	79.347	ISC-GEM	6.4	MW	ISC-GEM	20	ISC-GEM	40	10	EMS-98	Sarabia, A., Cifuentes Costa Pacífica, Pacífico				
22	22	1911/04/10	13:42	7.2	75.3	Di Giacom	6.4	MW	ISC-GEM	120	Di Giacom	11	7	EMS-98	Cifuentes, H., Sarabiz Yanumal, Antioquia				
23	23	1917/08/31	06:36	5.79	73.65	Di Giacom	7	MW	ISC-GEM	15	Di Giacom	67	6	EMS-98	Cifuentes, H., Sarabiz Villavicencio, Meta				
24	24	1923/12/14	05:31	0.87	77.78	Servicio Ge	5.2	MW	Servicio Ge	10	Servicio Ge	14	9	EMS-98	Sarabia, A., Cifuentes Cumbal, Nariño				
25	25	1923/12/22	04:56	5.56	73.51	Di Giacom	5.9	MW	Sarabia G8	15	Di Giacom	36	8	EMS-98	Sarabia, A., Cifuentes Medina, Cundinamarca				
26	26	1925/06/07	18:41	3.96	76.31	Di Giacom	6.1	MW	ISC-GEM	120	Di Giacom	54	7.5	EMS-98	Sarabia, A., Cifuentes Tulú, Valle del Cauca				
27	27	1926/12/18	20:50	0.87	77.78	Servicio Ge	6	MW	Servicio Ge	10	Servicio Ge	9	8	EMS-98	Servicio Geológico C. Cumbal, Nariño				
28	28	1928/11/01	11:08	4.95	73.097	Di Giacom	5.9	MW	Sarabia G8	15	Di Giacom	38	8	EMS-98	Barbosa Castro, D. Chinavita, Boyacá				
29	29	1933/02/10	17:00	1.37	77.58	Servicio Ge	5.7	MW	Servicio Ge	10	Servicio Ge	5	8	EMS-98	Servicio Geológico C. Linares, Nariño				
30	30	1935/08/07	04:02	1.05	77.31	Servicio Ge	6.1	MW	Servicio Ge	10	Servicio Ge	23	8	EMS-98	Sarabia, A., Cifuentes Tangua, Nariño				
31	31	1935/09/17	23:58	5.09	76.08	ISC-GEM	6.1	MW	ISC-GEM	15	ISC-GEM	20	8	EMS-98	Sarabia, A., Cifuentes Pueblo Rico, Risaralda				
32	32	1935/10/26	20:15	1.07	77.51	Servicio Ge	5.9	MW	Servicio Ge	10	Servicio Ge	20	8	EMS-98	Sarabia, A., Cifuentes Imúes, Nariño				
33	33	1936/01/09	23:30	1.1	77.6	Servicio Ge	5.6	MW	Servicio Ge	10	Servicio Ge	16	7	EMS-98	Sarabia, A., Cifuentes Túquerres, Nariño				
34	34	1936/07/17	12:30	1.17	77.73	Servicio Ge	6.3	MW	Servicio Ge	10	Servicio Ge	37	8	EMS-98	Sarabia, A., Cifuentes Túquerres, Nariño				
35	35	1938/02/04	21:23	4.68	75.69	Internation	7	MS	Internation	150	Internation	66	8	EMS-98	Cifuentes, H., Sarabiz Eje Cafetero, Colombia				
36	36	1942/05/22	05:30	4.44	74.64	Di Giacom	5.7	MW	Sarabia G8	15	Di Giacom	19	7	EMS-98	Cifuentes, H., Sarabiz Girardot, Cundinamarca				
37	37	1942/12/26	07:30	5.27	75.52	Di Giacom	6.2	MW	ISC-GEM	15	Di Giacom	13	8	EMS-98	Cifuentes, H., Sarabiz Santa Cruz de Lorica, Córdoba				
38	38	1947/07/14	07:01	1.28	77.74	Servicio Ge	6	MW	Servicio Ge	10	Servicio Ge	60	8	EMS-98	Cifuentes, H., Sarabiz San Juan de Pasto, Nariño				

Sheet0

Ready

Accessibility: Good to go

120%



<https://sish.sgc.gov.co/visor/sesionServlet?metodo=irAEpicentrosTodos&idDepartamento=&idMunicipio=&cuadranteXMin=&cuadranteXMax=&cuadranteYMin=&cuadranteYMax=>

Modelos Estadísticos: Regresión lineal y no lineal

a). Regresión lineal y no lineal

Breve introducción teórica:

- Modelo de regresión lineal simple y múltiple.
- Extensión a modelos no lineales: polinómica, exponencial.

Aplicación práctica:

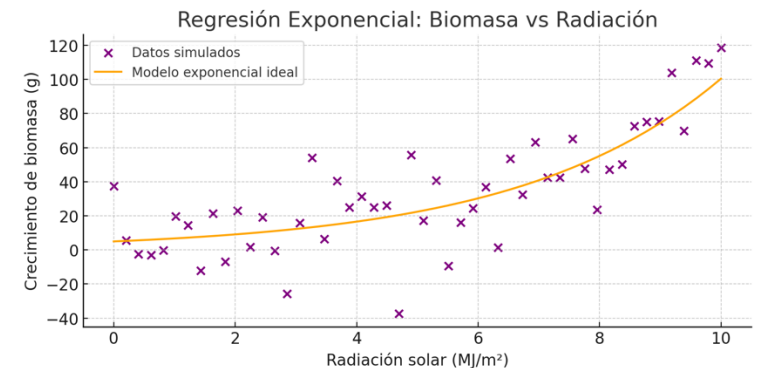


- Predecir tendencia de temperatura/precipitación o calidad del aire con datos históricos.

Modelos Estadísticos: Regresión lineal y no lineal

¿Qué es la regresión?

La regresión es una técnica estadística que permite modelar y analizar la relación entre una variable dependiente (*respuesta*) y una o más variables independientes (*predictoras*). Su objetivo principal es predecir valores de la variable dependiente basándose en el comportamiento de las independientes.

- Regresión Lineal Simple
- Regresión Lineal Multiple
- Regresión No Lineal
 - R. Polinómica
 - R. Exponencial



Modelos Estadísticos: Regresión lineal y no lineal

Regresión Lineal Simple

Es un modelo matemático que describe una relación lineal entre dos variables:

Modelo:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

y : variable dependiente

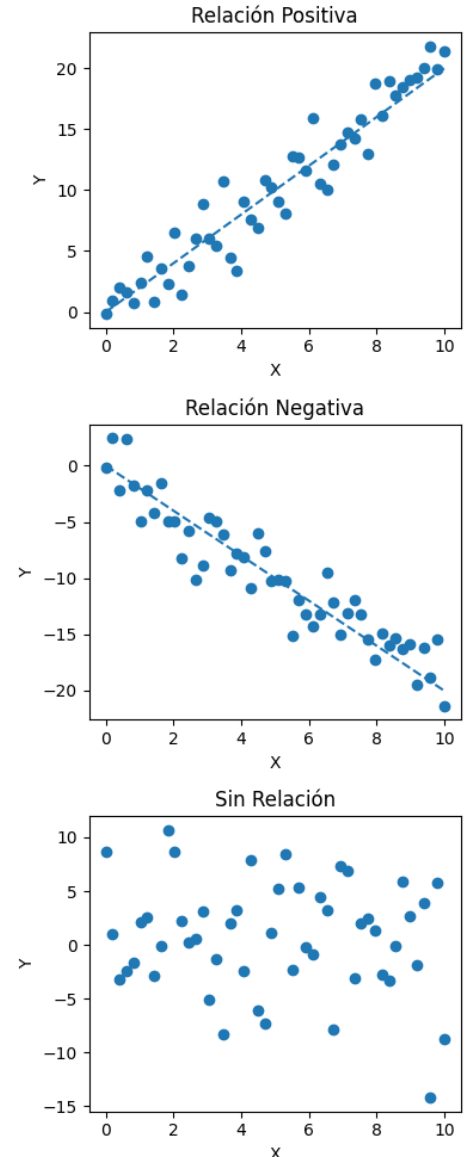
x : variable independiente

β_0 : intercepto

β_1 : pendiente (efecto del cambio de x sobre y)

ε : término de error aleatorio

Se utiliza cuando se busca predecir una variable en función de una sola variable explicativa.



Modelos Estadísticos: Regresión lineal y no lineal


Intercepto β_0 : Valor de y cuando $x = 0$.

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

Pendiente β_1 : Tasa de cambio de y por cada unidad de x .

$$\beta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

Error ε : Diferencia de cada punto a la línea del modelo. Línea que minimiza el error.



Modelos Estadísticos: Regresión lineal y no lineal

Predicción de caudal de un río en función del clima:

Se desea predecir el caudal diario (Q) de un río con base en variables meteorológicas. Se dispone de registros históricos de:

Q : Caudal simulado (en m^3/s).

P : Precipitación diaria (en mm).

T : Temperatura media diaria (en $^{\circ}\text{C}$).

R : Radiación solar diaria (en MJ/m^2).

$\varepsilon = np.random.normal(0, 5, size = n)$: Término de error aleatorio con distribución normal de media 0 y desviación estándar 5, que introduce variabilidad para simular datos más realistas.

$$Q = 0.5 * P + 0.3 * T + 0.2 * R + \varepsilon$$

Interpretación de los coeficientes

- **0.5:** Por cada milímetro adicional de precipitación, se espera un aumento de $0.5 \text{ m}^3/\text{s}$ en el caudal, manteniendo constantes las demás variables.
- **0.3:** Cada grado Celsius adicional en la temperatura media diaria se asocia con un incremento de $0.3 \text{ m}^3/\text{s}$ en el caudal, bajo las mismas condiciones.
- **0.2:** Un aumento de $1 \text{ MJ}/\text{m}^2$ en la radiación solar diaria se relaciona con un incremento de $0.2 \text{ m}^3/\text{s}$ en el caudal, considerando constantes las otras variables.

*Nota: **La formula de caudal, es una expresión utilizada para simular datos de caudal (Q) en función de variables climáticas: precipitación (P), temperatura (T) y radiación solar (R). Esta fórmula no proviene de un estudio específico, sino que se emplea para generar datos sintéticos con el propósito de practicar modelos de regresión lineal múltiple en un contexto ambiental.*

Modelos Estadísticos: Regresión lineal y no lineal

Regresión Lineal Multiple

Modelo:

$$y = X\beta + \varepsilon$$

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$$

Permite predecir una variable en función de varias variables explicativas x_1, x_2, \dots, x_p . Es útil cuando los fenómenos son complejos y dependen de múltiples factores.

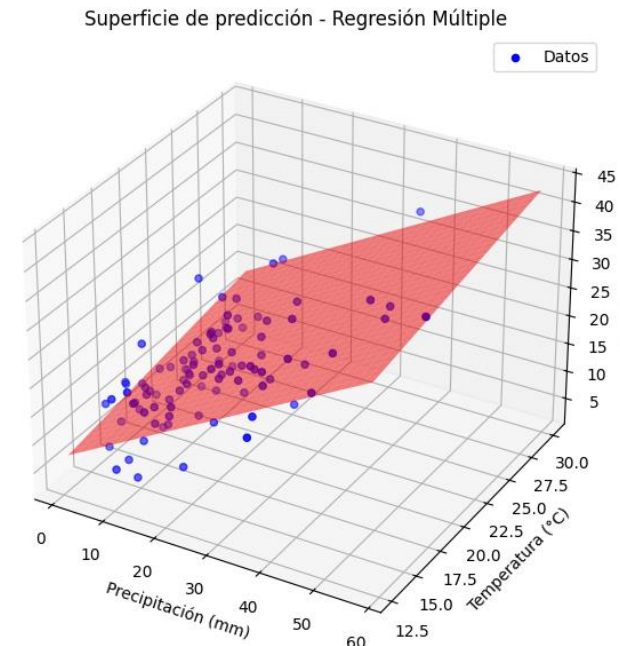
- Usamos **más de una variable independiente**.
- Ideal para sistemas complejos que dependen de múltiples factores.

Ejemplo:

$$Caudal = \beta_0 + \beta_1 \cdot Precipitación + \beta_2 \cdot Temperatura + \beta_3 \cdot Radiación + \varepsilon$$

Donde:

- y : vector columna con los valores observados de la variable dependiente
- X : matriz de diseño con las variables explicativas (incluye columna de unos para el intercepto)
- β : vector de coeficientes $[\beta_0, \beta_1, \dots, \beta_p]$
- ε : vector de errores (diferencia entre observado y predicho)



Modelos Estadísticos: Regresión lineal y no lineal

Extensiones: Regresión No Lineal

Es un modelo en el que la relación entre la variable dependiente y y las variables independientes x **no puede representarse como una combinación lineal simple** de los parámetros.

- En una regresión **lineal**, la relación es una recta.
- En una regresión **no lineal**, puede ser una curva:

a) Regresión Polinómica:

- Extiende la regresión lineal simple añadiendo potencias del predictor.
- Modelo con términos de orden superior.
- Permite capturar curvaturas en los datos.

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_k x^k + \varepsilon$$

Modelos Estadísticos: Regresión lineal y no lineal

a) Regresión Polinómica:

- Extiende la regresión lineal simple **añadiendo potencias del predictor**.
- Modelo con términos de orden superior.
- Permite capturar curvaturas en los datos.

$$y = \beta_0 + \beta_1x + \beta_2x^2 + \dots + \beta_kx^k + \varepsilon$$

Ventajas

- Captura relaciones más complejas que la recta.
- Se ajusta con herramientas de regresión lineal.
- Fácil de visualizar e interpretar hasta grado 2 o 3.

Desventajas:

- Usar grados muy altos puede llevar a **sobreajuste** (la curva sigue demasiado los datos, incluyendo el ruido).
- La interpretación de los coeficientes se vuelve menos intuitiva.

Ejemplo: Si tienes precipitación x y caudal y , puedes ajustar:

Regresión lineal:

$$y = \beta_0 + \beta_1x + \varepsilon$$

Regresión polinómica de grado 2:

$$y = \beta_0 + \beta_1x + \beta_2x^2$$

Grado 3:

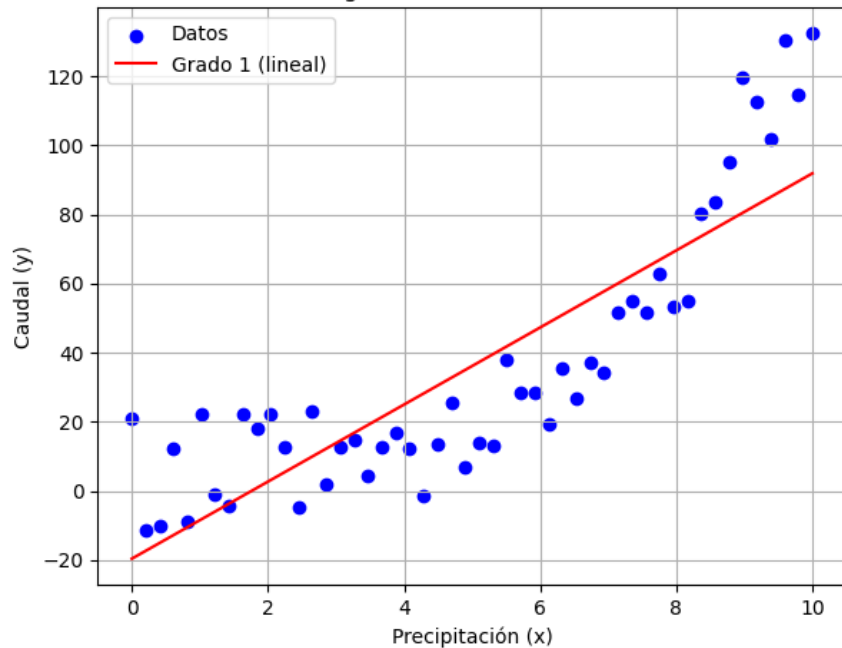
$$y = \beta_0 + \beta_1x + \beta_2x^2 + \beta_3x^3$$

Mientras más alto el grado, más flexible la curva, pero también puede sobreajustar - **overfitting**.

Modelos Estadísticos: Regresión lineal y no lineal

Regresión No Lineal - Regresión Polinómica

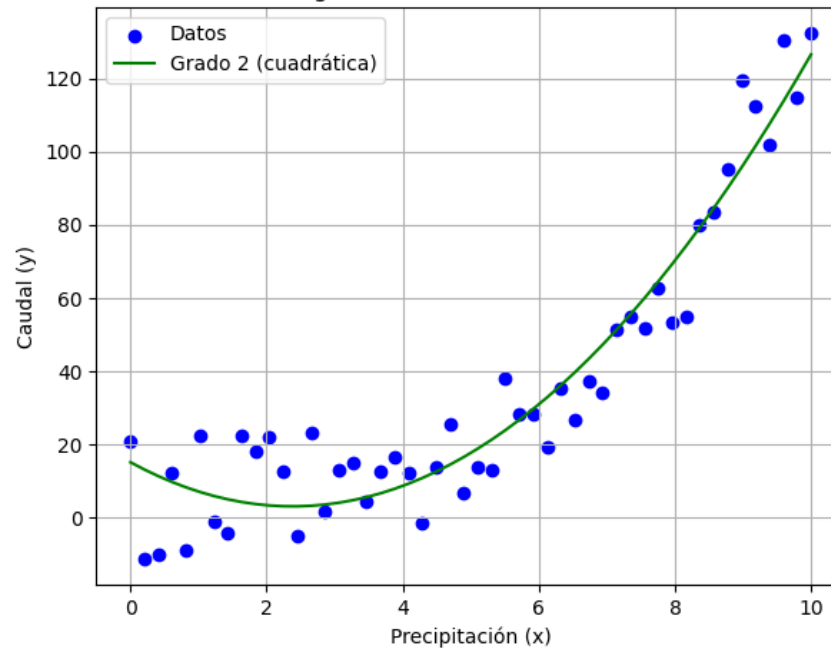
Regresión Lineal (Grado 1)



Regresión Lineal (Grado 1)

- La recta trata de ajustar los datos con una única pendiente.
- No capta la curvatura de la relación.


Regresión Polinómica (Grado 2)



Regresión Polinómica (Grado 2)

- La curva cuadrática (una parábola) comienza a ajustarse mejor a la forma de los datos.
- Ideal cuando la relación es simétrica y tiene un único mínimo o máximo.

Regresión Polinómica (Grado 3)



Regresión Polinómica (Grado 3)

- Modelo más flexible, capaz de adaptarse a cambios de curvatura.
- Puede captar mejor relaciones más complejas, pero también corre más riesgo de sobreajuste.

Modelos Estadísticos: Regresión lineal y no lineal

b) Regresión Exponencial:

Cuando el comportamiento entre variables sigue una forma **no lineal** y es muy útil cuando los datos siguen un patrón de **crecimiento o decaimiento acelerado**.

Ejemplo exponencial:

$$y = \beta_0 e^{\beta_1 x}$$

Este modelo no se puede ajustar directamente con regresión lineal, pero podemos **linealizarlo** tomando logaritmos:

$$\log(y) = \log(\beta_0) + \beta_1 x$$

$$y = \log(y)$$

$$\beta_0 = \log(\beta_0)$$

$$\beta_1 = \beta_1$$

Modelos Estadísticos: Regresión lineal y no lineal

✓ Paso 5: Regresión exponencial

Pregunta: ¿El caudal responde de forma exponencial a la precipitación?

```
1 import numpy as np
2 from sklearn.linear_model import LinearRegression
3
4 # Supongamos que tienes tus datos:
5 x = df[['Precipitacion_mm']]
6 y = df['Caudal_m3s']
7
8 # Transformar y aplicando logaritmo natural
9 y_log = np.log(np.where(y > 0, y, 0.1)) # para evitar log(0)
10
11 # Ajustar modelo lineal sobre log(y)
12 modelo_exp = LinearRegression().fit(x, y_log)
13
14 # Coeficientes:
15 print("log(a):", modelo_exp.intercept_)
16 print("b:", modelo_exp.coef_[0])
```

```
log(a): 2.2564735985253934
b: 0.030212994632717347
```

Contexto del modelo

Se trata de un modelo de regresión lineal que busca explicar la relación entre la precipitación y el caudal de un río. Pero en lugar de predecir directamente el caudal (y), se modela el logaritmo natural del caudal ($\log(y)$), lo cual implica que estamos asumiendo una relación exponencial entre ambas variables.

Regresión: ¿Cómo evaluamos si un modelo es bueno?

Métricas de Error en Modelos de Regresión

Se utilizan para evaluar el desempeño de un modelo de regresión.

- MAE (Error Absoluto Medio)
- MSE (Error Cuadrático Medio)
- RMSE (Raíz del Error Cuadrático Medio)
- R^2 (Coeficiente de Determinación)

Modelos de Regresión: Métricas de Error en Modelos de Regresión

MAE – Error Absoluto Medio

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Promedio del error absoluto.
- Fácil de interpretar.
- No penaliza errores grandes.

RMSE – Raíz del Error Cuadrático Medio

$$RMSE = \sqrt{MSE}$$

- MSE Similar al MSE, pero con las mismas unidades que y.
- Útil cuando se quiere interpretar el error en las mismas magnitudes del fenómeno.

MSE – Error Cuadrático Medio

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Promedio del cuadrado del error.
- Penaliza errores grandes más que el MAE.
- Muy usado en algoritmos de entrenamiento.

R² – Coeficiente de Determinación

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

- Mide la proporción de la varianza explicada por el modelo.
- Valores cercanos a 1 indican buen ajuste.
- Puede ser negativo si el modelo es peor que usar el promedio.

Modelos de Regresión: Métricas de Error en Modelos de Regresión

Métrica	Fórmula	Qué mide	Interpretación
R^2	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Varianza explicada por el modelo	1 = perfecto, 0 = nulo
MSE	$\frac{1}{n} \sum (y_i - \hat{y}_i)^2$	Error cuadrático medio	Penaliza errores grandes
RMSE	\sqrt{MSE}	Raíz del MSE, en unidades reales	Fácil de interpretar
MAE	$\frac{1}{n} \sum y_i - \hat{y}_i $	Error absoluto medio	Robusto ante valores atípicos

Table 1: Métricas comunes para evaluar modelos de regresión

Modelos de Regresión: Ejercicio

Modelos Estadísticos: Análisis de series temporales

b). Análisis de series temporales

Teoría:

- Tendencia, estacionalidad, ruido.

Aplicación práctica:

- Predecir demanda de energía, lluvia mensual, PM_{2.5}.

Modelos Estadísticos: Análisis de series temporales

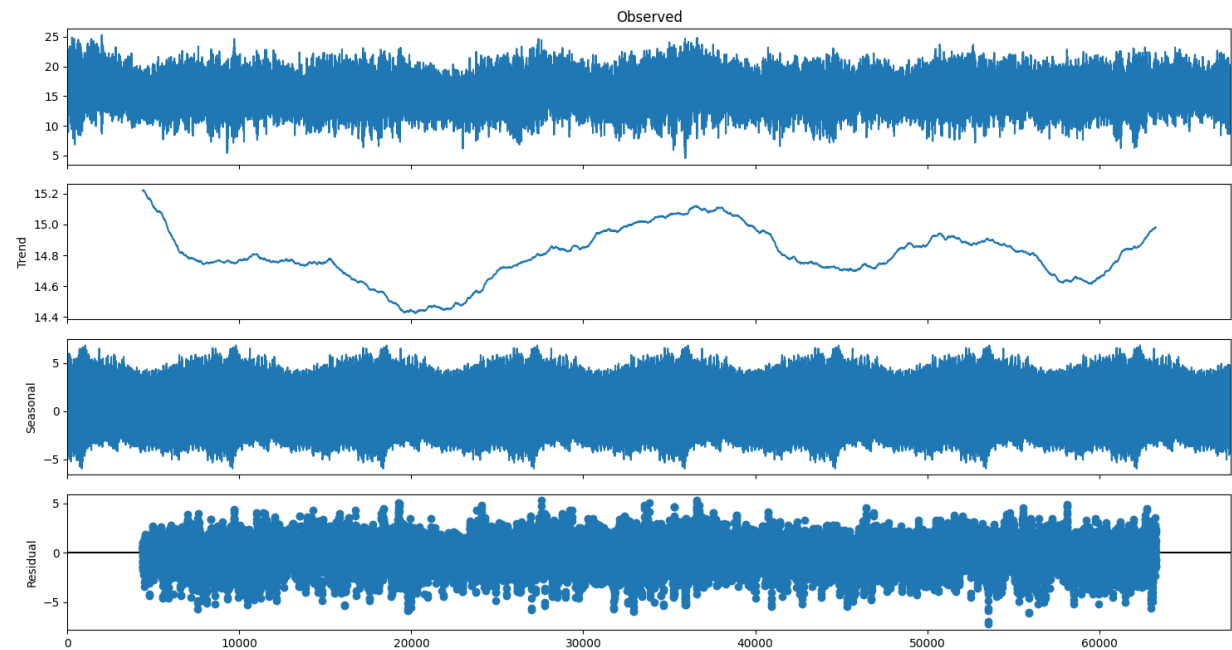
¿Qué es una serie temporal?

Es una secuencia de datos recolectados a lo largo del tiempo, con una frecuencia constante (horaria, diaria, mensual, etc.).

Componentes clave:


- **Tendencia (T):** cambio a largo plazo en el nivel de la serie.
- **Estacionalidad (S):** patrones que se repiten en intervalos fijos de tiempo (por ejemplo, estacionalidad mensual o diaria).
- **Ruido (R):** componente aleatorio no explicable por los anteriores.

```
seasonal_decompose()
```



Modelos Estadísticos: Análisis de series temporales

```
seasonal_decompose(promedio_hora.values, model='additive', period=8760)
```



Modelos Estadísticos: Análisis de series temporales

Datos Observados – Serie de Tiempo

Modelo Aditivo de Serie Temporal


$$Y_t = T_t + S_t + R_t$$

Y_t = valor observado en el tiempo t

T_t = componente de **tendencia**

S_t = componente de **estacionalidad**

R_t = componente de **ruido o residuo**




Modelos Estadísticos: Análisis de series temporales

Tendencia (T)

Es el **comportamiento general a largo plazo**. Puede ser creciente, decreciente o constante. Refleja cambios estructurales duraderos en el tiempo.

Se calcula usando una **media móvil** para suavizar los datos y eliminar fluctuaciones de corto plazo.

$$T_t = \frac{1}{k} \sum_{i=-m}^m Y_{t-i}$$




Modelos Estadísticos: Análisis de series temporales

Completación de Datos en Series de Tiempo

La **completación de datos** en series temporales es el proceso de **llenar los valores faltantes (NaN)** en una serie cronológica, asegurando que la información tenga una continuidad temporal adecuada.

Esto es clave para poder aplicar modelos estadísticos o de aprendizaje automático, ya que muchos de ellos no toleran valores nulos.




Modelos Estadísticos: Análisis de series temporales

Estacionalidad (S)

Son **patrones regulares y repetitivos** que se presentan en intervalos fijos, como días de la semana, meses del año o estaciones climáticas.

Se obtiene al **promediar los residuos de cada posición dentro del ciclo** (por ejemplo, los 12 meses si hay estacionalidad anual) **una vez eliminada la tendencia**.



Modelos Estadísticos: Análisis de series temporales


Ruido (R)

Es la **variabilidad aleatoria** o impredecible que no se explica por la tendencia ni por la estacionalidad. Se considera el “residuo” o error natural.

Una vez calculados los componentes de tendencia y estacionalidad, el residuo se obtiene como:

$$R_t = Y_t - T_t - S_t$$

Este componente **debería comportarse como ruido blanco**, es decir, sin patrón ni autocorrelación.



Modelos Estadísticos: Análisis de series temporales

¿Para qué sirve el residuo (RUIDO) en el análisis de series temporales?

El residuo (o ruido) es lo que queda de la serie original después de eliminar la tendencia y la estacionalidad. Se define como:

$$R_t = Y_t - T_t - S_t$$

¿Qué representa?

- El componente aleatorio o impredecible.
- Las perturbaciones externas no explicadas por patrones conocidos.
- Lo que un modelo no logra explicar.

¿Para qué se analiza el residuo?

1. Verificar si el modelo es adecuado:
 - Si el residuo no muestra patrón, el modelo (T + S) es bueno.
 - Si el residuo tiene estructura, puede que falte algo en el análisis.
2. Detección de eventos anómalos:
 - Valores extremos del residuo pueden indicar eventos inesperados (picos de contaminación, fallas, etc.).
3. Evaluar la aleatoriedad:
 - Un buen residuo debe parecer ruido blanco: sin autocorrelación y con media ≈ 0 .

Modelos Estadísticos: Análisis de series temporales

¿Cuándo usar el análisis de series temporales?

El análisis de series temporales se usa cuando los datos están organizados cronológicamente y el orden en el tiempo afecta el comportamiento de la variable. Es decir, el tiempo no es una variable más, sino que la estructura temporal influye en la dinámica.

Se usa cuando:

- Se espera que los datos tengan patrones repetitivos (ciclos, estacionalidad).
- Hay tendencias a largo plazo que se desean analizar.
- Se quiere hacer predicción futura (forecasting).
- Es necesario detectar anomalías o cambios de comportamiento en el tiempo.

Campo	Variable temporal común
Meteorología	Temperatura, precipitación, viento, PM2.5
Energía	Demanda eléctrica, consumo de gas
Economía/finanzas	Precios, inflación, ventas
Salud pública	Casos diarios de enfermedad, hospitalizaciones
Medio ambiente	Concentración de contaminantes, descargas
Hidrología	Caudal diario, recarga hídrica, nivel de ríos